Simulasi Sidang Laporan UTS

Klasifikasi Email Ham, Phish, dan Spam Menggunakan Stacking Multinomial Naive Bayes, Logistic Regression, dan LightGBM

IF2116 Pembelajaran Mesin · Kelompok 1 · Jason Nathanael (231110013) · Andrew Senna Wijaya (231111369)

Lembar persiapan, 8 November 2026

Tentang lembar ini. Lembar ini disusun dari simulasi lima penguji berbasis AI (Claude) yang membaca laporan akhir dan dokumen proyek. Setiap temuan dan angka sudah dicek ulang terhadap laporan, notebook, dan data mentah. Pertanyaan di sini adalah latihan, bukan pertanyaan resmi. Nomor bab ditulis dengan angka Arab, misalnya Bab 12 = BAB XII pada PDF laporan. Label risiko menunjukkan seberapa mudah jawaban kita goyah: **tinggi**, **sedang**, atau **rendah**.

1. Ringkasan

Kelima penguji menilai laporan dapat dipertahankan dan memenuhi persyaratan UTS: kedua belas butir minimum ada, dan struktur bab mengikuti panduan. Titik lemahnya ada pada tiga hal:

1. **Keputusan yang disesuaikan setelah hasil terlihat**: pemecah seri model akhir, urutan prioritas kesalahan yang berbeda dari Pertemuan 5, dan asal target 99,5%.
2. **Klaim tentang V3**: kalimat "tidak lagi bergantung pada perbedaan format" lebih kuat daripada buktinya.
3. **Catatan persiapan** (`DEFENSE_QA.md`, `DECISIONS_*.md`) masih memuat klaim yang lebih kuat daripada laporan akhir. Belajarlah dari laporan akhir, bukan dari catatan lama (lihat Bagian 3).

2. Masalah yang Terkonfirmasi di Laporan Akhir

Setiap baris sudah dicek terhadap berkas proyek. Jika laporan tidak diubah lagi, kolom kanan adalah cara menjawabnya di sidang.

Kode	Bagian	Masalah	Cara menjawab
A	8.3; Bab 12 butir 8	Kalimat "tidak lagi bergantung pada perbedaan format angka, tanggal, *stopword*, dan tautan" terlalu kuat. Pada V3, *chi-square* masih menempatkan `numtoken numtoken` (Ham) dan `urltoken numtoken` (Phish) di peringkat atas. `sirmadam` hanya muncul pada Phish (266 pesan), sedangkan Ham dan Spam menulis "sir madam" atau "sir/madam".	Perbedaan format yang paling kentara sudah dihapus, tetapi sisa ciri format masih ada, yaitu token yang menyatu pada sumber Phish.
B	2.6; 6.5	Urutan prioritas berbeda dari Pertemuan 5. Di sana spam masuk kotak masuk adalah prioritas ke-5 ("kesalahan yang sengaja diterima") dan phishing tanpa peringatan ke-3; di 2.6 menjadi ke-3 dan ke-4. Pemecah seri baru memakai Spam → Ham sebagai kriteria kedua.	Penentunya Phish → Ham, prioritas ke-2 di kedua urutan: 582 vs 746 (*bootstrap* 129–198). Model akhir menang dengan urutan mana pun.
C	8.5 butir 2	"b sedikit konservatif" hanya menjelaskan Ham Recall yang lebih tinggi. b yang lebih ketat justru menurunkan Macro F1 (0,8913 vs 0,8967 pada b = 0).	Macro F1 lebih tinggi terutama karena model akhir dilatih pada 100% data *training*.
D	7.4 langkah 4	Evaluasi *stacking* tidak sepenuhnya *nested*: *meta-model* untuk *fold* k belajar dari prediksi OOF *fold* lain, yang dibuat model dasar yang ikut dilatih dengan *fold* k.	Akui kebocoran tidak langsung. *Meta-model* hanya Logistic Regression dengan 9 fitur, dan hasil data *testing* tidak lebih rendah dari CV.
E	6.4; Tabel 8.4	"≥ 99,5%" hanya terpenuhi setelah pembulatan: 511 dari 102.192 = 0,99499961. Angka CV pada b dihitung pada prediksi yang sama dengan pemilihan b (dicatat di `DECISIONS_M05.md`).	Hanya satu angka yang dipilih, jadi optimismenya kecil. Data *testing*: 0,9963 (0,9956–0,9971).
F	3.1; Bab 14	Kartu dataset tidak menyebut korpus asal dan mengklaim "*deduplicated*" (`REFERENCES_VERIFIED.md` §0), padahal kita menemukan 84.498 duplikat. Laporan menulis asal korpus seolah fakta.	Asal korpus disimpulkan dari jejak teks: `enron`, `josemonkeyorg`, `uwaterloo`.
G	5.6; 8.2	Uji SMOTE/ketidakseimbangan (Hipotesis 3) dan SVD dilakukan pada teks V0 tanpa keterangan. Pada V0 Phish mudah (Recall ≈ 0,96); pada V3 hanya 0,62–0,68. SVD berasal dari Pertemuan 6 (`min_df` = 5, C = 1).	Akui bahwa kesimpulan itu berlaku untuk V0; uji ulang pada V3 dapat masuk rencana.
H	Bab 14	Laporan tidak menyebut bahwa data dan daftar *stopword* NLTK berbahasa Inggris.	Model belum berlaku untuk *email* berbahasa Indonesia; perlu data berlabel dan pemilihan b ulang.
I	7.2	Alasan menolak KNN ("jarak kehilangan makna") bertentangan dengan 9.4 (pencarian tetangga terdekat *cosine*) dan SMOTE (k-NN).	Alasan utamanya biaya: sekitar 44.600 × 178.000 perbandingan per *fold*.
J	15.1	Gambar 13.1 dibuat oleh `Gambar_13_1_Kata_Berpengaruh.ipynb` (path tertulis langsung), bukan `make_figures.py`. `requirements.txt`	Sebutkan terus terang; perbaikannya di luar laporan.

Kode	Bagian	Masalah	Cara menjawab
		memuat `python==3.13.18` sehingga `pip install -r` gagal, dan tidak mencantumkan `datasets` serta `imbalanced-learn`.	
K	Lain-lain	Bab 12 menyebut Macro F1 "tertinggi" padahal Bab 11 menyatakan seri. "Probabilitas Spam atau Phish" (6.4, 13.3) bisa dibaca sebagai jumlah, padahal yang dibandingkan adalah yang terbesar. Sampul menulis "Project ID 1", sedangkan panduan §4.2 memakai format A01/B01.	Cek Project ID ke koordinator sebelum mengumpulkan.

Tidak terbukti: klaim bahwa pemeriksaan nilai kosong melewatkan `nan`. Tidak ada pesan yang isinya hanya "nan"; kata `nan` muncul di dalam pesan (829 Phish, 158 Ham, 137 Spam). Tetap siapkan jawabannya.

Koreksi: `final_config.json` lokal sudah memuat model akhir (b = 1,7768). Catatan di `TODO.md` sudah usang, jadi berkas itu tidak perlu diganti.

3. Catatan Persiapan yang Bertentangan dengan Laporan Akhir

`DEFENSE_QA.md` disusun untuk versi laporan sebelumnya. Jika belajar dari sana, kita bisa mengucapkan hal yang tidak lagi diklaim laporan.

Catatan lama	Ucapkan ini (laporan akhir)
"Sebagian besar performa berasal dari format"; "0,978 terlalu tinggi, 0,891 angka jujur"	"Sebagian" (Abstrak, 8.3). Bandingkan CV dengan CV (Tabel 8.3); angka 0,978 tidak ada di laporan.
"Bukan kebetulan", "terbukti dengan *bootstrap*"	"Didukung oleh interval *bootstrap*" (Bab 12); "sangat kecil kemungkinannya…" (8.5)
"Model maupun b tidak *overfit*"	"Tidak ada indikasi … tidak berarti bebas dari *overfitting*" (8.5)
Meta-model "memercayai" atau "paling menentukan"	"Bukan ukuran pasti kontribusi" (13.1); rujuk Tabel 11.2
Semua aturan ditetapkan sebelum hasil; urutan prioritas "sudah ada sejak awal"	Pemecah seri diubah setelah hasil (6.5); urutan Pertemuan 5 berbeda
NLTK adalah "persis daftar" yang dipakai sumber Phish	"Kemungkinan besar sama" (4.3)
Skor uji pendahuluan LightGBM 0,9677 / 0,9675 / 0,9657	Hasil uji itu tidak tercatat (7.4); jangan kutip angkanya
Hipotesis 1 "didukung sebagian"	"Konsisten dengan data, tetapi belum diuji secara langsung" (9.2)
"511 *email* sah hilang di setiap baris"; "179 kata *stopword*"; "metrik bisnis: Phish Recall"	510–511 (Bab 11); 153 kata unik (4.3); Macro F1 metrik utama dan Ham Recall batasan (6.3)

4. Dua Belas Pertanyaan Berisiko Tertinggi

1. **"99,5% dari mana, dan siapa yang menetapkan?"** Laporan tidak menurunkan angka ini, dan `ROADMAP.md` mencatat target ini diusulkan oleh asisten AI. Keduanya harus bisa mempertahankannya sebagai keputusan kelompok: angka ini menerjemahkan kriteria *false positive* sangat rendah, dan Gambar 11.1 menunjukkan akibat target lain.
2. **"Kenapa *email* sah hilang lebih berat daripada phishing masuk kotak masuk?"** 99,5% adalah batas, bukan bobot tak terhingga. Phishing di kotak masuk tetap turun 80%. Akui tidak ada biaya kuantitatif, dan b bisa diubah.
3. **Pemecah seri dan urutan prioritas diubah setelah hasil terlihat** (masalah A–B). Akui terus terang; model akhir menang pada Phish → Ham dengan urutan mana pun, dan perubahan dilakukan sebelum data *testing* dipakai.
4. **"*Stacking*-nya tidak *nested*, bukan?"** Akui kebocoran tidak langsung; *meta-model* kecil, dan hasil *testing* tidak lebih rendah dari CV.
5. **"Sampel uji pendahuluan LightGBM berisi data *testing*?"** Tidak ada dokumen yang mencatatnya. Jawab bahwa hasilnya tidak tercatat, jangan kutip skornya, rujuk Bab 14.
6. **"`numtoken numtoken` masih pembeda teratas di V3; penurunan skor bukan bukti jalan pintas."** Akui tidak ada eksperimen kontrol. Penurunan terpusat pada Phish Recall, dan pada V0 17 dari 25 kata Phish terkuat adalah ciri format.
7. **Near-duplicate dengan kemiripan ≥ 0,99**: Ham 37,0%, Phish 20,0%, Spam 42,6% dari sampel *fold* 1. Angka ini tidak ada di laporan; hafalkan.
8. **"SMOTE hanya diuji di V0?"** Ya; akui (masalah G).
9. **"Unggul 4 dari 5 *fold*, uji tanda p ≈ 0,19."** Karena itu selisih Macro F1 disebut seri. Keputusan bertumpu pada kesalahan kotak masuk, yang interval *bootstrap* berpasangannya tidak memuat nol.
10. **"P = (0,12; 0,46; 0,42) tetap masuk kotak masuk?"** Ya. Aturannya membandingkan Ham dengan yang terbesar di antara Phish dan Spam, bukan jumlahnya. b dipilih dari data, bukan dari probabilitas yang terkalibrasi.
11. **"Apa kontribusi masing-masing?"** Tidak ada berkas yang mencatat siapa mengerjakan apa. Sepakati pembagiannya sebelum sidang.
12. **Pemakaian pada *email* Indonesia berformat HTML**, serta **penolakan KNN dan Random Forest** (masalah H dan I).

5. Empat Puluh Pertanyaan per Penguji

Penguji 1: Metodologi Evaluasi

> **P1.1 "Berapa kali data *testing* dipakai, dan kenapa ada validasi *hold-out* sekaligus lima *fold*?"**

Pemicu: 4.2, 6.1, 7.5

- Dua kali pada alur utama: baseline (Pertemuan 3) dan evaluasi akhir; baseline dihitung ulang tanpa perubahan sebagai pembanding (4.2, 8.5).
- Subbab 7.5 (Naive Bayes manual) juga memakai data *testing*, setelah evaluasi akhir, dan tidak memilih apa pun.
- *Hold-out* untuk perbandingan awal (Pertemuan 4); lima *fold* untuk *tuning*, b, dan pemilihan model.

Risiko: **rendah** Terdokumentasi. Sebutkan sendiri pemakaian di 7.5 sebelum ditanya.

> **P1.2 "Bagaimana kebocoran data dicegah? EDA dan aturan V3 dirancang dari data mentah, termasuk calon data *testing*?"**

Pemicu: 3.4, 4.1, 4.2

- Deduplikasi tidak mempelajari apa pun dari data dan dilakukan sebelum pembagian (4.1).
- *Vectorizer* dan *resampling* dilatih ulang di setiap *fold* (4.2).
- V3 hanya regex dan daftar tetap, tanpa parameter yang dipelajari; Gambar 3.2 dihitung pada data *training*.

Risiko: **sedang** Hitungan desain V2/V3 di `DECISIONS_M07.md` memakai seluruh 365.448 pesan mentah, termasuk calon data *testing*.

> **P1.3 "Hipotesis 1–3 berasal dari kesalahan baseline di data *testing*. Apakah data *testing* ikut mengarahkan desain?"**

Pemicu: 9.1

- Hipotesisnya umum dan hanya diuji pada validasi dan CV.
- Pola yang sama terlihat di validasi *hold-out*: Phish Recall 0,5144 dan Phish → Spam 2.858 (Tabel 7.2, 9.2).
- Model dan b ditetapkan dari CV saja (Bab 12).

Risiko: **sedang** Laporan sendiri menyebut hipotesis berasal dari kesalahan data *testing*; akui paparan ringan ini.

> **P1.4 "b dipilih dan Macro F1 0,8855 dihitung pada prediksi OOF yang sama. Lalu 511 dari 102.192 berarti Ham Recall 0,99499961, di bawah 99,5%?"**

Pemicu: 6.4, Tabel 8.4, Bab 11

- Hanya satu angka (b) yang dipilih dari 102.192 Ham, jadi optimismenya kecil; data *testing* memeriksanya sekali.
- b diambil dengan kuantil `method='lower'`; satu *email* tepat di batas, sehingga yang hilang 510–511.
- Pada data *testing*, Ham Recall 0,9963 (0,9956–0,9971), di atas target.

Risiko: **sedang** Laporan tidak menyebut kedua hal ini (masalah E).

P1.5 "CV 0,8855 berada di luar interval data *testing* 0,8878–0,8946. Bukankah b yang konservatif justru menurunkan Macro F1?"

Pemicu: 8.5, Tabel 8.7–8.8

- Penyebab utama: model akhir dilatih pada 100% data *training*, bukan 80%, dan kurva pembelajaran masih naik (9.6).
- b yang konservatif hanya menjelaskan Ham Recall; pada b = 0, Macro F1 0,8967 (Tabel 8.5).
- Interval yang tidak tumpang tindih adalah uji yang konservatif.

Risiko: sedang Butir kedua di 8.5 tidak menjelaskan Macro F1 (masalah C).

P1.6 "Sampel uji pendahuluan LightGBM diambil dari data *training* saja? Model *fold* 1 yang memilih jumlah pohon juga dipakai untuk prediksi OOF?"

Pemicu: 7.4, 6.1, Tabel 10.1

- Jawab terus terang: sampel sekitar 15% teks V0, hasilnya tidak tercatat (7.4). Jangan kutip skor uji pendahuluan; rujuk Bab 14 butir 7.
- 125 dan 150 pohon hanya berselisih 0,0007 pada *fold* 1, jadi bias OOF *fold* 1 kecil.

Risiko: tinggi Tidak ada dokumen yang menyebut apakah sampel itu bebas dari data *testing*, dan `CONSTANTS.md` masih memuat skor uji pendahuluan.

P1.7 "Untuk *fold* k, *meta-model* dilatih pada prediksi OOF *fold* lain, yang dibuat model dasar yang dilatih dengan *fold* k. *Stacking* ini tidak *nested*, bukan?"

Pemicu: 7.4 langkah 4

- Akui ada kebocoran tidak langsung; *meta-model* hanya Logistic Regression dengan sembilan fitur.
- *Nested* penuh melipatgandakan waktu LightGBM (sekitar 119 menit untuk lima *fold*); hasil data *testing* tidak lebih rendah dari CV.

Risiko: tinggi Laporan menggambarkan langkah ini seolah bebas kebocoran (masalah D).

P1.8 "Pemecah seri diubah setelah hasil terlihat, dan urutan prioritas di 2.6 berbeda dari Pertemuan 5. Apakah urutannya juga disesuaikan?"

Pemicu: 6.5, 2.6, Tabel 11.2

- Akui. Perubahan dilakukan sebelum data *testing* dipakai (run 4 November, evaluasi 5 November).
- Penentunya Phish → Ham, prioritas ke-2 di kedua urutan: 582 vs 746, *bootstrap* 129–198. Model akhir menang dengan urutan mana pun.

Risiko: tinggi `DEFENSE_QA.md` menyebut urutan itu "sudah ada sejak awal", padahal Pertemuan 5 berbeda (masalah B).

Penguji 2: Data dan Pra-pemrosesan

P2.1 "Dari mana sebenarnya dataset ini? Korpus apa yang digabung, dan apakah label Phish berarti phishing atau hanya berasal dari korpus phishing?"

Pemicu: 3.1, 3.6

- Kartu Hugging Face (salinan dari Kaggle, lisensi MIT) tidak menyebut korpus asal. Asal korpus disimpulkan dari jejak teks: `enron`, `josemonkeyorg`, `uwaterloo` (`REFERENCES_VERIFIED.md`).
- Perbedaan format diukur langsung (Gambar 3.2).
- Label mengikuti korpus asal (3.6 butir 2, 9.5, Bab 14 butir 3).

Risiko: sedang Laporan tidak menyebut bahwa asal korpus hanya disimpulkan (masalah F).

P2.2 "Phish hanya kehilangan 7 baris saat pembersihan, sedangkan Ham 40.715 dan Spam 45.785. Apa artinya? Mengapa 44 baris berlabel konflik dibuang semua?"

Pemicu: Tabel 3.1, 3.2, 4.1

- Duplikat terkonsentrasi pada Ham dan Spam, satu lagi tanda bahwa sumbernya berbeda; rasio Ham:Phish turun dari 3,93 menjadi 2,98 (3.2).
- Semua baris berlabel konflik dibuang karena label yang benar tidak dapat ditentukan (3.3).

Risiko: rendah Angkanya cocok.

P2.3 "Batas pencilan 590,5 kata memakai IQR linear, sedangkan *whisker* Gambar 3.1 dihitung pada skala log. Definisi mana yang berlaku? Apakah Phish benar paling pendek?"

Pemicu: 3.4, Gambar 3.1

- Batas 590,5 hanya deskriptif; tidak ada pesan yang dibuang (4.4).
- Gambar memakai skala log agar terbaca; garis putus-putus menandai batas 590,5, dan keterangannya menyebut 5.584 pesan yang tidak ditampilkan.
- Median Phish 55 kata vs Ham 161 dan Spam 110. Karena sumber Phish tidak memuat *stopword*, selisihnya kemungkinan sedikit dibesar-besarkan.

Risiko: sedang

P2.4 "Silhouette 0,09 dan ARI 0,38 menunjukkan klaster tidak stabil. Bagaimana klaster selemah itu menjadi bukti?"

Pemicu: 3.5, Tabel 3.3

- Klaster hanya memicu hipotesis; buktinya hitungan langsung (Gambar 3.2) dan ablasi V0–V3 (8.3).
- Ada klaster 99,8% Phish (17.281 pesan) yang kata teratasnya berupa *timestamp*.

Risiko: rendah

P2.5 "Mengapa *timestamp* dihapus seluruhnya, angka diganti `numtoken`, dan hanya `may` yang dikecualikan?"

Pemicu: 4.3

- Dua desain awal gagal: jika hanya angka diganti, urutan `datetoken numtoken …` tetap menjadi penanda Phish; jika hanya *timestamp* berangka asli yang dihapus, tanggal menjadi penanda Ham (4.3).
- Ham dan Spam tidak memuat angka asli, jadi `numtoken` menyamakan format tetapi tetap menyimpan informasi "ada angka".
- `may` biasanya kata kerja. Nama bulan dan hari lain diganti `datetoken` di semua kelas, jadi yang hilang hanya sedikit informasi, bukan jalan pintas baru.

Risiko: sedang

P2.6 "Bukti bahwa sumber Phish memakai daftar NLTK hanya median 0,0% dan kata `please`. Apakah 153 kata itu dicek satu per satu?"

Pemicu: 4.3

- Kata NLTK 0,00% dari seluruh kata Phish; kata yang hanya ada di daftar scikit-learn justru 6,8% pada Phish (`DECISIONS_M07.md`).
- Laporan sengaja menulis "kemungkinan besar sama" (4.3).
- Pengecekan per kata belum dilakukan; jika ada kata yang terhapus berlebih, efeknya sama di semua kelas.

Risiko: sedang

P2.7 "Deduplikasi dilakukan pada teks asli, tetapi model membaca V3. Apakah 'tidak ada teks yang sama' di 4.2 masih berlaku?"

Pemicu: 4.2, 9.4

- Untuk V3 yang diukur adalah *near-duplicate*: 55,2% pesan validasi punya pasangan dengan kemiripan ≥ 0,9, dengan tingkat kesalahan 7,37% vs 7,58% (9.4).
- Jujur: pada kemiripan ≥ 0,99 angkanya 37,0% Ham, 20,0% Phish, dan 42,6% Spam dari sampel *fold* 1 (notebook M07 R2, bagian C). Deduplikasi tidak diulang setelah V3.

Risiko: **tinggi** Angka ≥ 0,99 tidak ada di laporan.

P2.8 "Turunnya skor tidak membuktikan jalan pintas, karena V3 juga menghapus kata seperti `your`, `here`, dan `no`. Mengapa `numtoken numtoken` dan `urltoken numtoken` masih menjadi pembeda teratas di V3?"

Pemicu: 8.3

- Penurunan terpusat pada Phish Recall (0,9838 → 0,7297). Pada LR, Phish tanpa angka sudah sulit sejak V0 (0,650 vs 0,963 untuk Phish berangka; `DECISIONS_M07.md`).
- Pada V0, 17 dari 25 kata Phish terkuat adalah ciri format (Tabel 8.3).
- Akui tidak ada eksperimen kontrol (misalnya menghapus kata acak dalam jumlah sama), dan sisa ciri format masih ada (masalah A).

Risiko: **tinggi**

Penguji 3: Model dan Statistik

P3.1 "Tuliskan rumus Multinomial Naive Bayes dan jelaskan dengan rumus itu kenapa TF-IDF gagal."

Pemicu: 5.1–5.2, 7.5

- P(kata | c) = (F + α) / (T_c + α × |V|); prediksi = kelas dengan log P(c) + Σ f × log P(kata | c) terbesar; logaritma mencegah *underflow* (7.5).
- Bobot TF-IDF per pesan hanya beberapa satuan, sehingga total bobot Phish (207.178) hanya 0,31 kali tambahan *smoothing* (α × |V| = 664.008). α = 0,1 tanpa membuang kata memberi +0,0619 (5.1–5.2).
- Dengan frekuensi kata, total Phish 3.249.018, atau 4,9 kali *smoothing*; kata informatif muncul ribuan kali, jauh di atas α.

Risiko: **sedang** Argumen per kata harus dijelaskan secara lisan.

P3.2 "Logistic Regression *variance* tinggi (selisih 0,090), tetapi C = 64 berarti regularisasi lemah, di batas atas *grid*. Bukankah terbalik?"

Pemicu: 9.6, Bab 10

- C adalah kebalikan kekuatan regularisasi L2; dipilih pada V0 (16 → 64 hanya +0,0005) dan belum di-*tuning* ulang pada V3 (Bab 14 butir 7).
- Selisih besar tidak otomatis berarti C kecil lebih baik; skor validasi masih naik 0,8554 → 0,8630 dari 50% ke 100% data. Kurva C pada V3 masuk rencana (Bab 16 butir 1).

Risiko: **sedang**

P3.3 "KNN ditolak karena 'jarak kehilangan makna', padahal 9.4 mencari tetangga terdekat dengan *cosine* dan SMOTE memakai k-NN. Random Forest juga bisa dibuat ringan."

Pemicu: 7.2, 8.2, 9.4

- Alasan utama adalah biaya: sekitar 44.600 × 178.000 perbandingan per *fold*, sedangkan 9.4 hanya memakai 3.000 *email*. Akui argumen jarak terlalu kuat.

- Pertemuan 5 meminta minimal satu *ensemble*; LightGBM dipilih dan menjadi model tunggal terbaik (Tabel 11.1). KNN dan Random Forest dapat diuji setelah UTS.

Risiko: tinggi Laporan bertentangan dengan dirinya sendiri (masalah I).

> **P3.4 "Apa yang dipelajari setiap pohon LightGBM, dan kenapa `learning_rate` berinteraksi dengan jumlah pohon? Kenapa skor *training* MNB di Gambar 9.1(a) ikut naik?"**

Pemicu: 7.2, 9.6, Bab 10

- Setiap pohon memodelkan gradien negatif *log-loss* dan ditambahkan dengan bobot `learning_rate` 0,2 [10]; laju kecil butuh lebih banyak pohon. Pada *fold* 1: 125 pohon 0,8875 vs 150 pohon 0,8868.
- Kurva MNB memakai kosakata dari seluruh data *training fold* 1 untuk semua proporsi, sehingga pada 10% data α × |V| sangat dominan (mekanisme 5.1). Karena itu skor *training* dan validasi naik bersama.

Risiko: sedang Subbab 9.6 tidak menjelaskan kurva *training* yang naik.

> **P3.5 "Kenapa log-probabilitas dipotong di −30 lalu distandarkan? Bobot MNB hanya 6–11%; kenapa dipertahankan?"**

Pemicu: 7.4, 13.1, Tabel 11.2

- Masukan berupa prediksi OOF; e^−30 ≈ 10^{-13} sudah berarti "mustahil". Tanpa batas, log-probabilitas MNB (ribuan sampai jutaan negatif) mendominasi.
- Bobot bukan ukuran kontribusi (13.1); bukti utamanya ablasi: 164 phishing dan 456 spam lebih sedikit pada 511 Ham hilang yang sama (Tabel 11.2).

Risiko: sedang

> **P3.6 "Pada MNB, *oversampling* Phish praktis hanya menaikkan *prior*. Kenapa dibandingkan pada *threshold* bawaan, dan pada teks apa?"**

Pemicu: 8.2, 9.2

- Benar: duplikasi mengalikan F dan T_Phish, jadi P(kata | Phish) hampir tetap; yang berubah *prior* (setara *threshold*) dan pengaruh *smoothing*.
- Tanpa *threshold* pun PR-AUC Phish turun untuk semua teknik: 0,9346 tanpa penanganan vs 0,9254–0,9308 (notebook Pertemuan 5).
- Akui: diuji pada V0 (Macro F1 0,9441 = Tabel 8.1).

Risiko: tinggi Laporan tidak menyebut bahwa uji ini hanya pada V0 (masalah G).

> **P3.7 "Toleransi seri 0,001 disamakan dengan simpangan baku antar-*fold*, padahal perbandingannya berpasangan. Model akhir unggul pada 4 dari 5 *fold*: uji tanda p ≈ 0,19. Apa yang diabaikan *bootstrap* Tabel 11.2?"**

Pemicu: 6.5, Tabel 11.2, 8.7

- Justru karena tidak signifikan, selisih 0,0008 disebut seri; keputusan bertumpu pada kesalahan kotak masuk dengan *bootstrap* berpasangan yang tidak memuat nol.
- Akui: *bootstrap* memakai b tetap dan tidak mencakup variasi pelatihan.
- Interval Tabel 8.7 yang tidak tumpang tindih adalah uji yang konservatif.

Risiko: tinggi

P3.8 "'Probabilitas Spam atau Phish' dijumlahkan? Jika tidak, P = (0,12; 0,46; 0,42) tetap masuk kotak masuk walaupun 88% bukan Ham. Tanpa kalibrasi, apa arti '5,9 kali'?"

Pemicu: 6.4, 13.3

- Tidak dijumlahkan: setelah b ditambahkan dipilih kelas terbesar, jadi Ham dibandingkan dengan yang terbesar di antara Phish dan Spam (`CONSTANTS.md` 3.5).
- b sama dengan mengalikan probabilitas Ham dengan e^b; jika probabilitas terkalibrasi, setara rasio biaya sekitar 5,9. Tanpa kalibrasi b tetap sah karena dipilih dari prediksi OOF dan dicek sekali (0,9963).
- Aturan P(Ham) vs P(Phish) + P(Spam) dapat diuji setelah UTS.

Risiko: tinggi Tidak dibahas di laporan.

Penguji 4: Rumusan Masalah dan Kesimpulan

P4.1 "Jelaskan singkat: masalahnya apa, siapa penggunanya, dan kenapa harus *machine learning*, bukan aturan atau daftar blokir?"

Pemicu: 1.1, 2.2–2.4

- Ham → kotak masuk, Spam → *folder* spam, Phish → *folder* spam dengan peringatan (2.2); pengguna sesuai *stakeholder* tahap *Business Understanding* (2.3).
- Ciri ancaman ada pada kata dan frasa dan terus berubah; tersedia 278.941 *email* berlabel (2.4).
- Jujur: pembanding berbasis aturan tidak diuji.

Risiko: rendah

P4.2 "Angka 99,5% dari mana, siapa yang menetapkan, dan apa artinya bagi organisasi?"

Pemicu: 2.6

- Kriteria sukses tahap *Business Understanding* meminta *false positive* sangat rendah; 99,5% menerjemahkannya menjadi paling banyak 1 dari 200 *email* sah hilang, ditetapkan pada Pertemuan 5 sebelum pemilihan model.
- Pada data *testing*: 94 dari 25.548 (0,37%); batas bawah interval 0,9956 (Tabel 8.7).
- *System Administrator* dapat mengubah b; Gambar 11.1 menunjukkan akibat target lain.

Risiko: tinggi Laporan tidak memberi alasan angka ini, dan `ROADMAP.md` mencatat target ini diusulkan oleh asisten AI. Keduanya harus bisa mempertahankannya sebagai keputusan kelompok.

P4.3 "Tim IT Security menerima *email* bertanda Phish. Spam → Phish naik dari 65 ke 612, dan sekitar 30% phishing tidak diberi peringatan. Apa yang sebenarnya mereka dapat?"

Pemicu: 2.3, Tabel 8.6

- Phish Precision 0,9055: sekitar 1 dari 11 peringatan salah, tetapi *email* itu tetap di luar kotak masuk.
- Phishing yang diberi peringatan naik dari 4.555 menjadi 5.913 (Gambar 8.2); hanya 1,25% phishing masuk kotak masuk.

Risiko: sedang Tidak ada target untuk Phish Recall.

P4.4 "Bab 12 menulis 'Macro F1 tertinggi', padahal Bab 11 menyatakan seri. Kenapa Macro F1 jadi metrik utama kalau Phish ↔ Spam adalah prioritas paling ringan?"

Pemicu: Bab 12 butir 2, 6.3, 6.5

- Prioritas 1 dikunci sama untuk semua model (510–511 Ham hilang).
- Pada titik itu model akhir paling rendah untuk Phish → Ham (582) dan Spam → Ham (3.089) di antara semua model (Tabel 11.1), jadi pilihan tidak bergantung pada Macro F1.

Risiko: sedang Masalah K.

P4.5 "Abstrak menyebut penurunan 0,10–0,13 karena format sumber. Bukankah V3 juga membuang informasi asli, seperti negasi?"

Pemicu: Abstrak, 17.1, 8.3

- Klaimnya "sebagian", bukan seluruhnya.
- Pada V0, 17 dari 25 kata Phish terkuat adalah ciri format (Tabel 8.3).
- Angka 0,10–0,13 mencakup jalan pintas dan informasi yang ikut terhapus; karena itu laporan menulis "sebagian". Hilangnya negasi dicatat di Bab 14.

Risiko: sedang

P4.6 "Rencana Bab 16 masih umum. Metode apa, dataset luar apa, dan kapan dianggap berhasil?"

Pemicu: Bab 16

- *Tuning* ulang C dan tiga parameter LightGBM pada V3 (Bab 10), serta V3 dengan kata negasi dipertahankan (9.7).
- Model lain dari materi kuliah, misalnya SVM linear (panduan bagian 19), dan *permutation importance*.
- Uji pada korpus *email* publik lain; dianggap berhasil jika lebih baik daripada model akhir pada Ham Recall 99,5% dengan protokol Bab 6.

Risiko: sedang Rencana tertulis tidak menyebut hal-hal ini; sepakati jawabannya bersama sebelum sidang.

P4.7 "Kalau dipasang di organisasi Indonesia, *email*-nya berbahasa Indonesia, berformat HTML, dan isinya baru. Apakah model ini masih berlaku?"

Pemicu: 2.2, Bab 14 butir 1 dan 8, Bab 16 butir 5

- Jujur: data dan daftar *stopword* NLTK berbahasa Inggris, dan korpusnya lama (Enron; *timestamp* 2008).
- *Email* masuk harus diproses sama (huruf kecil, V3); model perlu dilatih ulang dan b dipilih ulang pada *email* berlabel milik organisasi.
- Demo hanya prototipe (Bab 16 butir 5).

Risiko: tinggi Laporan tidak menyebut cakupan bahasa (masalah H).

P4.8 "Kenapa *email* sah hilang lebih berat daripada phishing masuk kotak masuk? Bab 1.1 menyebut phishing dapat membocorkan data, dan *email* yang 'hilang' sebenarnya ada di *folder* spam. b menyelamatkan 208 Ham, tetapi meloloskan 74 phishing tambahan."

Pemicu: 1.1, 2.2, 2.6, 8.5

- 99,5% adalah batas, bukan bobot tak terhingga: b hanya sebesar yang diperlukan untuk mencapainya.
- Phishing di kotak masuk tetap turun 80% dibandingkan baseline (538 → 107).
- Jujur: tidak ada biaya kesalahan kuantitatif; organisasi yang mengutamakan keamanan dapat menurunkan b (Gambar 11.1).

Risiko: tinggi Satu-satunya alasan di laporan ("sesuai dengan urutan prioritas bisnis") bersifat melingkar.

Penguji 5: Konsistensi dan Reproduksibilitas

P5.1 "Pemecah seri diubah setelah hasil terlihat. Apa bedanya dengan memilih hasil yang disukai?"

Pemicu: 6.5

- Perubahan diungkapkan di 6.5 dan dilakukan sebelum data *testing* dipakai.

- Urutannya mengikuti prioritas 2.6, kesederhanaan tetap kriteria terakhir, dan selisihnya didukung *bootstrap* (Tabel 11.2).
- Akui bahwa aturan ini ditetapkan setelah hasil terlihat.

Risiko: tinggi Catatan persiapan masih menulis "terbukti".

P5.2 "Di `experiment_log.csv`, pada *threshold* bawaan *stack* A 0,8922 dan model akhir 0,8909. Kenapa bukan A?"

Pemicu: `experiment_log.csv`, Tabel 8.4

- Pemilihan dilakukan pada Ham Recall 99,5% agar *email* sah yang hilang setara (6.4, Bab 11).
- Pada b = 0, Ham Recall model akhir 0,9879, di bawah target (Tabel 8.4); pada target, selisih 0,0008 dianggap seri.

Risiko: sedang Keunggulan A pada *threshold* bawaan tidak ada di laporan.

P5.3 "Hasil data *testing* lebih tinggi dari CV; jadi model tidak *overfitting*?"

Pemicu: 8.5

- Tidak. Artinya hanya tidak ada indikasi pemilihan model dan b pada CV terlalu optimistis (8.5).
- Selisih *training*–validasi Logistic Regression 0,0903 dan Multinomial Naive Bayes 0,0472 (9.6).

Risiko: sedang `DECISIONS_FINAL.md` menulis sebaliknya.

P5.4 "Jika saya jalankan ulang, apakah 0,8913 keluar lagi?"

Pemicu: 6.6, 15.2

- `random_state=42`; evaluasi akhir membaca `final_config.json` dan `oof_log_proba.npz` (15.2).
- Baseline tereproduksi persis (0,8881; 0,8377; 0,5316) di evaluasi akhir dan di notebook manual.
- Akui: revisi dataset belum dikunci, dan baris `python==` di `requirements.txt` harus dihapus agar `pip install` berjalan.

Risiko: sedang

P5.5 "Tunjukkan di kode cara b dipilih dan dipakai."

Pemicu: 6.4

- `ham_bias_for_target`: b dihitung dari kuantil (`method='lower'`) selisih antara log P(Ham) dan log-probabilitas kelas lain terbesar pada *email* Ham OOF, sehingga 99,5% Ham tetap menang setelah b ditambahkan.
- `predict_with_ham_bias`: b ditambahkan ke log P(Ham), lalu dipilih kelas terbesar; e^1,777 ≈ 5,9.
- Satu *email* tepat di batas menyebabkan 510–511 (Bab 11).

Risiko: rendah

P5.6 "Pada 7.5, apa yang ditulis sendiri? Hitung *posterior* teks 'verify password'."

Pemicu: Tabel 7.4

- Tokenisasi, frekuensi, P(c), P(kata | c), log S_c, prediksi, dan metrik ditulis sendiri; scikit-learn hanya pembanding.
- Pecahan 12/1014 dan 2/1014, *posterior* Phish 0,75 (`DECISIONS_MANUAL_NB.md`, B.2).
- 0 dari 55.789 prediksi berbeda; Macro F1 0,9337 tidak dibandingkan dengan model akhir karena memakai teks V0.

Risiko: sedang Anggota yang menulisnya harus bisa menghitung langsung.

P5.7 "Apa kontribusi masing-masing anggota? Siapa yang menetapkan 99,5%?"

Pemicu: sampul, `ROADMAP.md`

- Sebutkan pembagian kerja yang nyata per notebook atau bab.
- 99,5% menerjemahkan kriteria *false positive* sangat rendah (2.6); akibatnya terlihat pada Gambar 11.1.
- Akui bantuan AI sesuai panduan; setiap anggota dapat menjelaskan kodenya.

Risiko: tinggi Tidak ada berkas yang mencatat siapa mengerjakan apa. `ROADMAP.md` menulis target "*proposed by Claude*", sedangkan `CONSTANTS.md` menulis "*user decision*".

P5.8 "`CONSTANTS.md` memuat skor uji pendahuluan 0,9677, tetapi laporan menyebut hasilnya tidak tercatat. Mana yang benar?"

Pemicu: 7.4, Tabel 10.1, 15.3

- Laporan yang benar: hasil uji tidak tersimpan di notebook, jadi angka itu tidak dapat ditelusuri (7.4, Tabel 10.1).
- Jumlah pohon di-*tuning* ulang pada V3 (125); sisanya dicatat sebagai keterbatasan (Bab 14 butir 7).

Risiko: tinggi

6. Angka yang Perlu Dihafal

Hal	Angka (rujukan)
Data	365.448 mentah → 278.941 bersih (Tabel 4.1); *training* 223.152, *testing* 55.789 (Tabel 4.2); Ham:Phish 3,93:1 → 2,98:1
Pencilan	> 590,5 kata; 30.385 pesan (8,31%) (3.4)
Format sumber	`escape`… 75,1 / 0,3 / 67,0%; angka asli 12,2 / 93,4 / 10,2% untuk Ham / Phish / Spam (Gambar 3.2)
V0 → V3 (Macro F1 CV)	MNB 0,9344 → 0,8016; LR 0,9687 → 0,8658 (Tabel 8.3)
Baseline (*testing*)	Akurasi 0,8881; Macro F1 0,8377; Phish Recall 0,5316 (Tabel 7.1)
Model akhir (CV)	Macro F1 0,8855 ± 0,0011 pada b = 1,777; 511 dari 102.192 Ham hilang (Tabel 8.4, Bab 11)
Threshold	b = 1,777; e^1,777 ≈ 5,9 (6.4)
Model akhir (*testing*)	Macro F1 0,8913 (0,8878–0,8946); Ham Recall 0,9963 (0,9956–0,9971); Phish Recall 0,6901 (Tabel 8.5, 8.7)
Kesalahan baseline → akhir	Ham hilang 174 → 94; Phish → Ham 538 → 107; Spam → Ham 1.991 → 781; Phish → Spam 3.475 → 2.548; Spam → Phish 65 → 612 (Tabel 8.6)
Pengaruh b (*testing*)	b = 0 → 1,777: Ham hilang 302 → 94; Phish → Ham 33 → 107; Spam → Ham 244 → 781 (8.5)
Stack A vs model akhir (CV)	Phish → Ham 746 vs 582 (*bootstrap* 129–198); Spam → Ham 3.545 vs 3.089 (394–524); Macro F1 0,8847 vs 0,8855; unggul 4 dari 5 *fold* (Tabel 11.2)
Hiperparameter	α = 2,0; C = 64; LightGBM 125 pohon, `learning_rate` 0,2, `num_leaves` 63, `colsample_bytree` 0,3; toleransi seri 0,001; ambang hipotesis 0,005
Near-duplicate	55,2% (≥ 0,9); kesalahan 7,37% vs 7,58% (9.4); ≥ 0,99: Ham 37,0%, Phish 20,0%, Spam 42,6% (notebook M07 R2)
Waktu pelatihan	LightGBM 33 menit; MNB 3,4 menit (seluruh data *training*)
Naive Bayes manual	0 dari 55.789 prediksi berbeda; Macro F1 0,9337 (Tabel 7.5)